

Chapter 8: Transformers এত সফল কেন?

Transformers বর্তমানে সবচেয়ে শক্তিশালী neural network architecture, বিশেষ করে **Natural Language Processing (NLP)**-এ।

এছাড়াও এখন **Computer Vision** (image processing)-এও এটি state-of-the-art হয়ে উঠছে।


Transformers-এর সাফল্য মূলত চারটি প্রধান কারণে নির্ভর করে:

1. Attention Mechanism
2. Self-supervised Pretraining
3. Large Number of Parameters
4. Easy Parallelization

এখন আমরা একে একে এগুলো বুঝি।

1. Attention Mechanism (সবচেয়ে গুরুত্বপূর্ণ)

Transformer-এর সবচেয়ে বড় শক্তি হলো **self-attention mechanism**।



সহজভাবে ব্যাখ্যা:

ধরো একটি sentence:

"The cat sat on the mat because it was tired"

এখানে "it" কোনটিকে নির্দেশ করছে?

→ "cat"

Transformer কী করে?

- প্রতিটি word অন্য সব word-এর সাথে তুলনা করে
- কোন word বেশি গুরুত্বপূর্ণ তা নির্ধারণ করে

মূল ধারণা:

প্রতিটি word বাক্যের অন্য সব word-এর দিকে attention দেয়।

Self-Attention কী করে?

- প্রতিটি token (word) অন্য সব token-এর সাথে সম্পর্ক খুঁজে বের করে
- গুরুত্বপূর্ণ word-গুলোকে বেশি weight দেয়

উদাহরণ:

- "cat" → বেশি গুরুত্বপূর্ণ
- "the" → কম গুরুত্বপূর্ণ

গুরুত্বপূর্ণ পার্থক্য (পরীক্ষার জন্য গুরুত্বপূর্ণ)

Fully Connected Layer:

- Training-এর পরে weights স্থির থাকে

Attention Mechanism:

- Weights পরিবর্তনশীল (input অনুযায়ী পরিবর্তিত হয়)

এর মানে:

একই transformer model ভিন্ন input-এর জন্য ভিন্নভাবে কাজ করতে পারে।

Attention কেন শক্তিশালী?

- এটি context বুঝতে পারে
- বড় sentence সহজে handle করতে পারে
- গুরুত্বপূর্ণ তথ্যের উপর focus করে

এই কারণেই transformer অনেক বেশি accurate।

2. Pretraining (Self-Supervised Learning)

Transformer প্রথমে বড় dataset দিয়ে training করা হয়, যেখানে কোনো label থাকে না।

এটি কী শেখে?

- missing word predict করা
- next sentence predict করা

উদাহরণ:

"I love ____ learning"

→ model অনুমান করবে "machine"

সুবিধা:

- ভাষার গঠন নিজে নিজে শিখে ফেলে
- পরে ছোট task-এর জন্য fine-tune করা যায়

এই প্রক্রিয়াকে বলা হয়:

Pretrain → Fine-tune

3. Large Number of Parameters

Transformer model সাধারণত অনেক বড় হয়।

উদাহরণ:

- GPT-3 → 175 billion parameters

Parameter কী?

Parameter হলো model-এর শেখার ক্ষমতা।

- বেশি parameter → বেশি জ্ঞান শিখতে পারে
- জটিল pattern বুঝতে পারে

Scaling Law (গুরুত্বপূর্ণ ধারণা)

যখন model size বাড়ে:

- training loss কমে
- performance বাড়ে

নিয়ম:


model size দ্বিগুণ হলে $\rightarrow$ training data-ও দ্বিগুণ হওয়া উচিত

গুরুত্বপূর্ণ বিষয়:

বড় data + বড় model = সবচেয়ে ভালো performance

4. Easy Parallelization

Transformer training দ্রুত হয় কারণ এটি parallel computation support করে।



পুরনো মডেলের সমস্যা (RNN):

- sequential processing (একটার পর একটা)
- ধীরগতি

Transformer কী করে?

- সব token একসাথে process করে
- GPU-তে দ্রুত run করে

উদাহরণ:

Self-attention-এ:

- সব word একসাথে compare হয়
- computation গুলো independent

ফলাফল:

- দ্রুত training
- বড় model ব্যবহার করা সম্ভব